

CAPITULO III NÚMEROS ALEATORIOS

3.1 Introducción.

La simulación de cualquier sistema o proceso donde existen componentes aleatorios necesita de números al azar, un número aleatorio es un número de una secuencia cuya probabilidad de ocurrencia es igual a la de cualquier otro número de la secuencia. Disponer de un buen generador de números aleatorios es fundamental en cualquier simulación. Constituye también una parte fundamental en otras áreas, como la Informática (algoritmos aleatorizados, verificación de algoritmos, complejidad de algoritmos, criptografía, ...), la Estadística (métodos de muestreo y remuestreo, contrastes Montecarlo, Inferencia Bayesiana, ...), y, en general, en cualquier problema de cálculo científico que, de manera directa o indirecta, incluya algún elemento probabilístico incluyendo los juegos de video.

Actualmente existen múltiples generadores de números aleatorios en diferentes entornos y compiladores lo cual supondría para un usuario de la Simulación que no es necesario su estudio. Sin embargo, observaciones sobre algunos generadores comerciales sugieren que debemos actuar con cuidado con el uso de ellos. Incluso, el uso progresivo de modelos de simulación cada vez más detallados exige generadores de números aleatorios de mayor calidad. La forma de generar números aleatorios tiene mucha historia, desde los primeros métodos que se llevaron esencialmente a mano (Manuales) como lanzar dados, retirar cartas, agitar urnas y muchas de las loterías en la actualidad todavía son muy utilizadas. A medida que las computadoras han revolucionado tecnológicamente ha aumentado la atención en la generación de números aleatorios de forma numérica, aritmética, algorítmica de formas secuenciales, como el método de la raíz media que dio inicio a la gran cantidad de algoritmos y su utilización en los diferentes problemas de simulación. Algunos autores siguen discutiendo que realmente los generadores por algoritmos aritméticos no son realmente números aleatorios sino llamados pseudoaleatorios.

El inicio en la generación de números aleatorios con Métodos Manuales, los mismos que son laboriosos y no muy prácticos se utiliza en procesos tales como:

- Ruleta
- Baraja
- Dados
- Lanzamientos de moneda
- **Las DESVENTAJAS:**
- No es reproducible
- Lento
- No se pueden usar en computadores

Luego continúa con Métodos generados por Equipos Eléctricos como:

- RAND(Rand Corporation (1955) utilizado para generar una tabla de un millón de números aleatorios proveniente de las mediciones del ruido eléctrico)
- ERNIE(Electronic Random Number Indicator Equipment, utilizado para generar números aleatorios para la lotería)

Y por último los generados por Computador Digital (Algoritmos Matemáticos) que en la década del 1950 se convertiría en la época en la que se generara números aleatorios de forma aritmética, estos métodos son secuenciales con cada número nuevo obtenido por uno o varios de sus predecesores de acuerdo a una fórmula matemática fija. Uno de los primeros métodos propuestos por Von Neuman y Metropolis, con el famoso método de los **cuadrados medios** que resumimos a continuación, pero debemos señalar que los números aleatorios llamados propiamente pseudoaleatorios que deben cumplir con ciertas características:

- Deben ser uniformemente distribuidos $u[0,1]$
- Estadísticamente independiente (La correlación entre los números generados sea mínimos y se mide entre números consecutivos.
- Debe ser reproducible
- Generar a grandes velocidades
- Mínimo almacenamiento
- Sin repetición, con largos periodos

Método de los cuadrados medios

La primera técnica de generación de números pseudoaleatorios conocida como técnica del **cuadrado medio**. que consta de los siguientes pasos:

- Seleccione un valor inicial o "semilla" (r).
- Determinamos el número de dígitos
- Elévese al cuadrado el valor inicial.
- Tómense los n dígitos centrales del cuadrado del número anterior
- Repítase el proceso cuantas veces sea necesario.

In [10]:

```

1  # Método de Los cuadrados medios
2  import pandas as pd
3  import numpy as np
4  import matplotlib.pyplot as plt
5  n=100
6  #r=7182                                # seleccionamos el valor inicial r
7  r=171                                # seleccionamos el valor inicial r
8  l=len(str(r))                          # determinamos el número de dígitos
9  lista = []                            # almacenamos en una lista
10 lista2 = []
11 i=1
12 #while len(lista) == len(set(lista)):
13 while i < n:
14     x=str(r*r)                          # Elevamos al cuadrado r
15     if l % 2 == 0:
16         x = x.zfill(l*2)
17     else:
18         x = x.zfill(l)
19     y=(len(x)-1)/2
20     y=int(y)
21     r=int(x[y:y+1])
22     lista.append(r)
23     lista2.append(x)
24     i=i+1
25
26 df = pd.DataFrame({'X2':lista2,'Xi':lista})
27 dfrac = df["Xi"]/10**l
28
29 df["ri"] = dfrac
30 #df.head()
31 df

```

Out[10]:

	X2	Xi	ri
0	29241	924	0.924
1	853776	537	0.537
2	288369	883	0.883
3	779689	796	0.796
4	633616	336	0.336
5	112896	128	0.128
6	16384	638	0.638
7	407044	70	0.070
8	4900	490	0.490
9	240100	401	0.401
10	160801	608	0.608
11	369664	696	0.696
12	484416	844	0.844
13	712336	123	0.123

	X2	Xi	ri
14	15129	512	0.512
15	262144	621	0.621
16	385641	856	0.856
17	732736	327	0.327
18	106929	69	0.069
19	4761	476	0.476
20	226576	265	0.265
21	70225	22	0.022
22	484	484	0.484
23	234256	342	0.342
24	116964	169	0.169
25	28561	856	0.856
26	732736	327	0.327
27	106929	69	0.069
28	4761	476	0.476
29	226576	265	0.265
...
69	116964	169	0.169
70	28561	856	0.856
71	732736	327	0.327
72	106929	69	0.069
73	4761	476	0.476
74	226576	265	0.265
75	70225	22	0.022
76	484	484	0.484
77	234256	342	0.342
78	116964	169	0.169
79	28561	856	0.856
80	732736	327	0.327
81	106929	69	0.069
82	4761	476	0.476
83	226576	265	0.265
84	70225	22	0.022
85	484	484	0.484
86	234256	342	0.342
87	116964	169	0.169

	X2	Xi	ri
88	28561	856	0.856
89	732736	327	0.327
90	106929	69	0.069
91	4761	476	0.476
92	226576	265	0.265
93	70225	22	0.022
94	484	484	0.484
95	234256	342	0.342
96	116964	169	0.169
97	28561	856	0.856
98	732736	327	0.327


99 rows × 3 columns

```
In [11]: 1 df.tail()  
        2
```

Out[11]:

	X2	Xi	ri
94	484	484	0.484
95	234256	342	0.342
96	116964	169	0.169
97	28561	856	0.856
98	732736	327	0.327

```
In [12]: 1 ### Graficando Los numeros aleatorios generados
2 # seleccionamos del dataframe Los números generados
3 x1=df['ri']
4 plt.plot(x1)
5 plt.title('Generador de Numeros Aleatorios Cuadrados Medios')
6 plt.xlabel('Serie')
7 plt.ylabel('Aleatorios')
8 plt.show()
```



Análisis del método de cuadrados medios ¶

Como podemos observar los Numeros Aleatorios generados por los cuadrados medios con muy pocos numeros generados no cumplen con los principios de los numeros aleatorios como: **Sin repetición, con largos periodos**, por lo tanto para utilizar este método hay que ser muy cuidadoso en la selección de la semilla.

en el código anterior podemos cambiar la cantidad de numeros **n**** y/o la semilla ****r**, donde observaremos facilmente que este método no favorece para la simulación.

3.2 Métodos congruenciales lineales

La mayoría de los generadores de números aleatorios que se utilizan hoy son los congruenciales lineales, Lehmer (1951) incorporo una secuencia de números enteros X_1, X_2, X_3, X_4 , definida como una formula recursiva de la siguiente forma:

- $X_{n+1} = (aX_n + c) \pmod{m}$
- $X_{n+2} = (aX_{n+1} + c) \pmod{m}$
 - X_n = Semilla
 - a = multiplicador
 - c = incremento
 - m = modulo
 - Que son enteros positivos

Propiedades:

- $0 < m$, $a < m$, $c < m$
- $r_i = X_{n+1} / m$

Como el caso anterior de los **cuadrados medios** se debe seleccionar cuidadosamente a, c, m, X_n ya que de estas variables depende la calidad y el cumplimiento de los requisitos para ser considerado un buen generador de números aleatorios.

Ejemplo

$m = 1000$, $a = 101$, $c = 457$, $X_0 = 4$

```

In [8]: 1 # Generador de números aleatorios Congruencia Lineal
2 n, m, a, x0, c = 20, 1000, 101, 4, 457
3 x = [1] * n
4 r = [0.1] * n
5 print(" Método de Congruencia Lineal ")
6 print("-----")
7 print("n=cantidad de números generados : ", n)
8 print()
9 print("m : ", m)
10 print("a : ", a)
11 print("c : ", c)
12 print("Xo : ", x0 )
13
14 for i in range(0, n):
15     x[i] = ((a*x0)+c) % m
16     x0 = x[i]
17     r[i] = x0 / m
18 # Llenamos nuestro DataFrame
19 d = {'Xn': x, 'ri': r }
20 df = pd.DataFrame(data=d)
21 df
22

```

```

Método de Congruencia Lineal
-----
n=cantidad de números generados :  20

m :  1000
a :  101
c :  457
Xo :  4

```

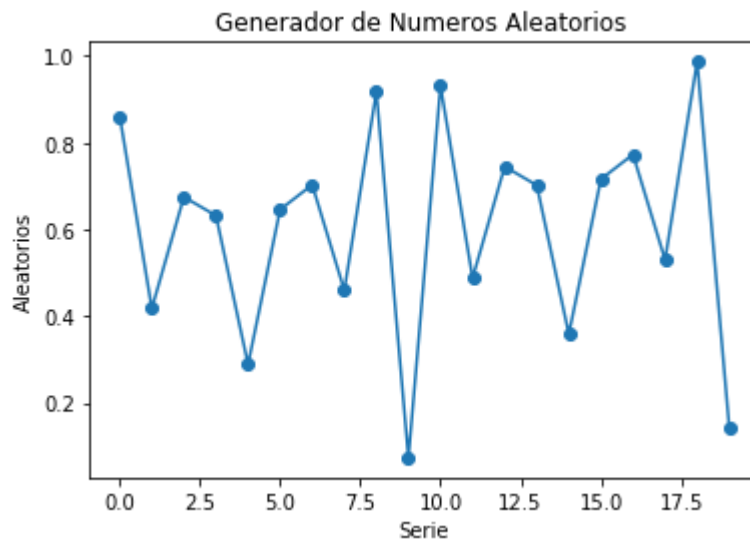
Out[8]:

	Xn	ri
0	861	0.861
1	418	0.418
2	675	0.675
3	632	0.632
4	289	0.289
5	646	0.646
6	703	0.703
7	460	0.460
8	917	0.917
9	74	0.074
10	931	0.931
11	488	0.488
12	745	0.745
13	702	0.702
14	359	0.359

	Xn	ri
15	716	0.716
16	773	0.773
17	530	0.530
18	987	0.987
19	144	0.144

```
In [9]: 1 # Graficamos los numeros generados
2 plt.plot(r,marker='o')
3 plt.title('Generador de Numeros Aleatorios ')
4 plt.xlabel('Serie')
5 plt.ylabel('Aleatorios')
6
```

Out[9]: Text(0, 0.5, 'Aleatorios')



Congruenciales multiplicativo

EL método multiplicativo congruencial es otro caso especial, donde la constante $c=0$ quedando la sucesión de la siguiente forma:

$$X_{n+1} = (aX_n) \pmod{m}$$

Se ha demostrado que este método se comporta aceptablemente desde el punto de vista estadístico. Con éste método el periodo máximo es $m/4$ y para asegurar esta propiedad cuando se utilizan computadoras binarias se consideran los siguientes criterios en la selección de los parámetros.

- La elección de m debe hacerse mediante la relación:
 - $m = 2^b$, ($b > 2$) para computadora binaria
 - X_n o sea el valor inicial o semilla deberá ser numero primo.
- En cuanto al valor de la constante a su valor podrá ser de Los números primos y además $a < m$,

para el ejemplo vamos a utilizar los datos de un generador de la hoja electrónica Excel-03, Excel-07 *Wichman y Hill (1982) :

- $X_{n+1} = (171X_n) \pmod{30264}$
- $X_{n+1} = (172X_n) \pmod{30307}$
- $X_{n+1} = (170X_n) \pmod{30323}$

Ejemplo 1 : $X_{n+1} = (171X_n) \pmod{30264}$

```

In [10]: 1 # generador excel-03
2 # -  $X_{n+1} = (171X_n) \pmod{30264}$ 
3 n, m, a, x0 = 20, 1000, 747, 123
4 x = [1] * n
5 r = [0.1] * n
6 print(" Generador Congruencial multiplicativo")
7 print("-----")
8 for i in range(0, n):
9     x[i] = (a*x0) % m
10    x0 = x[i]
11    r[i] = x0 / m
12 d = {'Xn': x, 'ri': r }
13 df = pd.DataFrame(data=d)
14 df
15

```

Generador Congruencial multiplicativo

Out[10]:

	Xn	ri
0	881	0.881
1	107	0.107
2	929	0.929
3	963	0.963
4	361	0.361
5	667	0.667
6	249	0.249
7	3	0.003
8	241	0.241
9	27	0.027
10	169	0.169
11	243	0.243
12	521	0.521
13	187	0.187
14	689	0.689
15	683	0.683
16	201	0.201
17	147	0.147
18	809	0.809
19	323	0.323

Ejemplo 2 : $X_{n+1} = (172X_n) \pmod{30307}$

```

In [11]: 1 # generador excel-07
2 # -  $X_{n+1} = (172X_n) \pmod{30307}$ 
3
4 n, m, a, x0 = 20, 30307, 172, 172
5 x = [1] * n
6 r = [0.1] * n
7 print (" Generador Congruencial multiplicativo")
8 print ("-----")
9 for i in range(0, n):
10     x[i] = (a*x0) % m
11     x0 = x[i]
12     r[i] = x0 / m
13 d = {'Xn': x, 'ri': r }
14 df1 = pd.DataFrame(data=d)
15 df1.head()
16

```

Generador Congruencial multiplicativo

Out[11]:

	Xn	ri
0	29584	0.976144
1	27179	0.896790
2	7510	0.247798
3	18826	0.621177
4	25530	0.842380

Ejemplo 3 : $X_{n+1} = (170X_n) \pmod{30323}$

```
In [12]: 1 # generador excel-07
2 # -  $X_{n+1} = (170X_n) \pmod{30323}$ 
3
4 n, m, a, x0 = 20, 30323, 170, 170
5 x = [1] * n
6 r = [0.1] * n
7 print (" Generador Congruencial multiplicativo")
8 print ("-----")
9 for i in range(0, n):
10     x[i] = (a*x0) % m
11     x0 = x[i]
12     r[i] = x0 / m
13 d = {'Xn': x, 'ri': r }
14 df2 = pd.DataFrame(data=d)
15 df2.head()
16
```

Generador Congruencial multiplicativo

Out[12]:

	Xn	ri
0	28900	0.953072
1	674	0.022227
2	23611	0.778650
3	11234	0.370478
4	29754	0.981235

```
In [13]: 1 df2.tail()
2
```


Out[13]:

	Xn	ri
15	8516	0.280843
16	22539	0.743297
17	10932	0.360518
18	8737	0.288131
19	29786	0.982291

Gráficamos los números aleatorios generados


```
In [14]: 1 plt.plot(r,'g-', marker='o',)
2         plt.title('Generador de Numeros Aleatorios ')
3         plt.xlabel('Serie')
4         plt.ylabel('Aleatorios')
5
```

Out[14]: Text(0, 0.5, 'Aleatorios')



```
In [15]: 1 x1 = df["ri"]
2         x1.plot.area()
```

Out[15]: <matplotlib.axes._subplots.AxesSubplot at 0x1d14a6cf4a8>




```
In [ ]: 1
```

Graficamos los tres modelos de generadores con sus diferentes constantes a,m,xo

```
In [16]: 1 import matplotlib as mpl
2 import matplotlib.pyplot as plt
3 import numpy as np
4
5 x1 = df["ri"]
6 x2 = df1["ri"]
7 x3 = df2["ri"]
8 x = np.arange(n)
9
10 #fig = plt.figure()
11 plt.figure(figsize=(15,5))
12 # Gráfico 1
13 plt.subplot(131)
14 x1 = df["ri"]
15 p1, = plt.plot(x,x1,'r-',marker='o')
16 plt.ylabel('# Aleatorios')
17 plt.title(' Xn+1 = (172Xn ) (mod 30307) ')
18
19 # Gráfico 2
20 plt.subplot(132)
21 x2 = df1["ri"]
22 p1, = plt.plot(x,x2,'b-',marker='o')
23 plt.title(' Xn+1 = (172Xn ) (mod 30307) ')
24
25 # Gráfico 2
26 plt.subplot(133)
27 x3 = df2["ri"]
28 p1, = plt.plot(x,x3,'g-',marker='o')
29 plt.title(' Xn+1 = (170Xn ) (mod 30323) ')
30
31
```

Out[16]: Text(0.5, 1.0, ' Xn+1 = (170Xn) (mod 30323) ')



Conclusiones

En el gráfico podemos observar que las constantes a,m,xo son importantes en la generación de números aleatorios

3.3 Otros Generadores utilizados

David Ríos 2009, propone los siguientes ejercicios para analizar el comportamiento de estos generadores aleatorios:

- RANDU $x_{i+1} = 65539x_i \bmod 2^{31}$
- Sinclair ZX81 $x_{i+1} = 75x_i \bmod (2^{16} + 1)$
- Numerical recipes $x_{i+1} = 1664525x_i + 1013904223 \bmod 2^{32}$
- Borland C/C++ $x_{i+1} = 22695477x_i + 1 \bmod 2^{32}$

En el siguiente código generamos los números para observar su comportamiento,

In [17]:

```

1  # Generador de números aleatorios Congruencia Lineal
2  # Borland C/C++  $x_{i+1} = 22695477x_i + 1 \bmod 2^{32}$ 
3
4  n, m, a, x0, c = 200, 2**32, 22695477, 4, 1
5  x = [1] * n
6  r = [0.1] * n
7  print (" Método de Congruencia Lineal Utilizado por:")
8  print ("Borland C/C++  $x_{i+1} = 22695477x_i + 1 \bmod 2^{32}$  ")
9  print ("n=cantidad de números generados : ", n)
10 print()
11 print ("m : ", m)
12 print ("a : ", a)
13 print ("c : ", c)
14 print ("Xo : ", x0 )
15
16 for i in range(0, n):
17     x[i] = ((a*x0)+c) % m
18     x0 = x[i]
19     r[i] = x0 / m
20 # Llenamos nuestro DataFrame
21 d = {'Xn': x, 'ri': r }
22 dfMCL = pd.DataFrame(data=d)
23 dfMCL
24

```

```
11 2046132792 0.476402
```

```
12 221316505 0.051529
```

```
13 1000654510 0.232983
```

```
14 349316615 0.081332
```

```
15 3163423092 0.736542
```

```
16 1151313157 0.268061
```

```
17 3793137674 0.883159
```

```
18 2782494227 0.647850
```

```
19 2024432 0.000471
```

```
20 2184728753 0.508672
```


```
21 762880678 0.177622
```

```
22 4293148767 0.999577
```


```
23 2252621228 0.524479
```

```
...
```

```
In [18]: 1 # Gráficos de dispersión
2 plt.title('Generador de Numeros Aleatorios ')
3 plt.xlabel('Serie')
4 plt.ylabel('Aleatorios')
5
6 #plt.scatter(df.index,df['ri'])
7 plt.plot(r,marker='o')
8 plt.show()
```




```
In [19]: 1 rS= df['ri']
2 #rS
3 plt.figure(figsize=(10,5))
4 plt.hist(rS,bins=20,color='blue')
5 plt.xlabel('# Aleatorios generados')
6 plt.ylabel('Ocurrencias en rangos')
7 plt.show()
8
9 #Aqui podemos observar en la grafica los números generados para lo cual se h
```



Gráficamos la dispersión del generador

```
In [20]: 1 # utilizamos scatter
2 plt.scatter(df.index,df['ri'])
```

Out[20]: <matplotlib.collections.PathCollection at 0x1d14ab08710>



Generador random de Python np.random.rand

Python cuenta con el módulo random para generación de números pseudo-aleatorios.

Contiene diversos métodos que corresponden a varias formas de generar este tipo de números. genera numeros aleatorios con una distribución uniforme [0,1] entre 0.0 excepto 1.0, la facilidad es que puede generar diferentes numeros aleatorios con diferentes intervalos y diferentes distribuciones que más adelante utilizaremos.

In [21]:

```
1 # para obtener la ayuda del módulo random debemos importar random
2 # y nos muestra la documentación completa del módulo random
3
4 import random
5 help(random)
6
```

chooses k unique random elements from a population sequence or set.

Returns a new list containing elements from the population while leaving the original population unchanged. The resulting list is in selection order so that all sub-slices will also be valid random samples. This allows raffle winners (the sample) to be partitioned into grand prize and second place winners (the subslices).

Members of the population need not be hashable or unique. If the population contains repeats, then each occurrence is a possible selection in the sample.

To choose a sample in a range of integers, use range as an argument. This is especially fast and space efficient for sampling from a large population: sample(range(10000000), 60)

seed(a=None, version=2) method of Random instance
Initialize internal state from hashable object.

None or no argument seeds from current time or from an operating


In [22]:

```
1 # genera un número aleatorio con dsitribución uniforme
2 np.random.rand()
3
```

Out[22]: 0.6482488570713822

```
In [23]: 1 # Generamos otro número aleatorio con distribución normal
2 lista=np.random.randn(100)
3 lista
4 #Lista.plot.area()
5 dfl =pd.DataFrame({'X1':lista})
6 dfl.head()
7 x1.plot.hist()
8
```

Out[23]: <matplotlib.axes._subplots.AxesSubplot at 0x1d14ab33be0>



```
In [24]: 1 # generamos un arreglo de 5 números aleatorios distribución uniforme
2
3 np.random.rand(5)
```

Out[24]: array([0.52480589, 0.47801364, 0.56811539, 0.3635772 , 0.28420988])

```
In [25]: 1 # generamos una matriz de números aleatorios de 2 filas y 4 columnas
2 np.random.rand(2,4)
3
```

Out[25]: array([[0.70656049, 0.9610001 , 0.96418141, 0.38559339],
[0.93244932, 0.6778016 , 0.62711745, 0.09130302]])

Inicialización del generador de números mediante el método **random.seed()**.

Aún cuando no es obligatorio, se sugiere utilizar este método para inicializar el generador de números aleatorios.

Ejemplo:

```
In [26]: 1 import random
2         # primer número generado con la misma semilla
3         random.seed(10)
4         print(random.random())
5         print("Observamos como el nuevo numero generado va a ser igual")
6         # segundo número generado con la misma semilla
7         random.seed(10)
8         print(random.random())
9
```

0.5714025946899135

Observamos como el nuevo numero generado va a ser igual

0.5714025946899135

Igual forma utilizando Random de numpy


```
In [27]: 1 # podemos cambiar la semilla de la secuencia de # aleatorios generados
2         np.random.seed(100)
3         x = np.random.rand(50)
4         df = pd.DataFrame({'Xn': x})
5         df.head()
6
```

Out[27]:

	Xn
0	0.543405
1	0.278369
2	0.424518
3	0.844776
4	0.004719

```
In [28]: 1 df.plot()
```

Out[28]: <matplotlib.axes._subplots.AxesSubplot at 0x1d14a2ebfd0>



los dos secuencias de numeros aleatorios es la misma igual que el grafico

```

1 # Serie 2
2 np.random.seed(100)
3 y = np.random.rand(61)
4 print(y)
5 dfy = pd.DataFrame({'Yn': y})
6 dfy

```

In [29]:

```

1 # Graficamos la serie 2 que va a ser igua a la primera
2
3 dfy.plot()
4

```

```

-----
NameError                                Traceback (most recent call last)
<ipython-input-29-dd2c4b9847ee> in <module>
      1 # Graficamos la serie 2 que va a ser igua a la primera
      2
----> 3 dfy.plot()

NameError: name 'dfy' is not defined

```

Obtención de un número entero aleatorio dentro de un rango *random.randint()*.

Generará un número aleatorio que va dentro del rango ingresado.

In []:

```

1 # generamos 10 números aleatorios con size=10 y los numeros entre 1 y 10
2 np.random.randint(10, size=10)
3

```

3.4 Test de números aleatorios

Una cuestión clave para un proyecto de simulación es saber si la secuencia de números aleatorios es suficientemente aleatoria. Como vemos en los generadores y gráficos anteriores que una secuencia aleatoria en función de su apariencia no es suficiente para determinar si un número generado es **aleatorio**", la realidad nos dice que antes de que realmente se use en simulación identifiquemos al generador, sus parámetros y que al menos se haya realizado alguna prueba que a continuación lo desarrollaremos.

```

**"Ninguna cantidad de pruebas puede probar que un GNA dado sea perfect
o".**

```

Prueba de frecuencia en bloques

El enfoque de esta prueba es la proporción de **1** dentro de bloques de **m** bits. El propósito es determinar si una frecuencia de **1** dentro de un bloque es aproximadamente **m/2**, como se esperaría de la aleatoriedad.

Parámetros

- m longitud de cda bloque
- n longitud de la lista de datos
- vector lista con la secuencia de bits 1 y 0

Procedimiento

Procedimiento:

1. Partición de la secuencia en bloques de tamaño N , descartando bits no usados.

$$N = \left(\frac{n}{M} \right)$$

2. Determinar la proporción de unos con la fórmula:

$$\pi_i = \frac{\sum_{j=1}^M \mathcal{E}_{(i-1)M+j}}{M}, \text{ for } 1 \leq i \leq N.$$

3. Calcular la prueba estadística:

$$\chi^2(obs) = 4M \sum_{i=1}^N (\pi_i - 1/2)^2$$

4. Calcular P - value usando la fórmula:

$$P\text{-value} = \text{chidist}(\chi^2(obs), df)$$

Donde chidist es la distribución chi al cuadrado y df es el grado de libertad (número de bloques - 1)

5. Si el valor de P - value < 0.01, se concluye que la secuencia no es aleatoria. De otra forma la secuencia es aleatoria.

Procedimiento de: Emanuel Garcia (Modelado y Simulación)

In []:

1

Type *Markdown* and LaTeX: α^2

In [30]:

```

1  # Prueba de Frecuencias en bloques
2
3  import math
4  from scipy.stats import chi2
5  rS
6  lista1=np.array(rS)
7  vector = []
8  # Llenamos de 0 y 1
9  for i in range (0,len(lista1)-1):
10     if lista1[i] < lista1[i+1]:
11         vector.append(0)
12     else:
13         vector.append(1)
14  #vector
15  m = 10                                # numero de bloques
16  n = len(vector)                        # longitud de la lista
17  N = int(n/m)                           # número de elementos de cada bloque
18
19  blocks = []
20  i = 0
21  while(len(blocks) != N):
22     blocks.append(vector[i:(i+m)])
23     i = i + m
24  sumas = []
25  for i in range(len(blocks)):
26     sumas.append(0)
27     for j in range(len(blocks[i])):
28         sumas[i] = sumas[i] + blocks[i][j]/float(m)
29  x_2 = 0
30  for i in range(N):
31     x_2 = x_2 + math.pow((sumas[i] - .5),2)
32  x_2 = x_2 * 4*m
33  df = m - 1
34  p_value = chi2.cdf(x_2, df)
35  if p_value < 0.01:
36     print ("Test de frecuencia en Bloques: Not Pasa")
37  else:
38     print ("Test de frecuencia en Bloques : Aprobado")
39
40  print ("Valor de P_value es %3f y el de Chi cuadrado es %3f " % (p_value, x_2))
41  print ("La proporción del bloque de sumas es:")
42
43  titulo = []
44  n=20
45  for i in range(n):
46     titulo.append(float(i))
47
48  print(titulo)
49  print("Sumas")
50  print (sumas)
51

```

Test de frecuencia en Bloques: Not Pasa

Valor de P_value es 0.000000 y el de Chi cuadrado es 0.000000

La proporción del bloque de sumas es:

[0.0, 1.0, 2.0, 3.0, 4.0, 5.0, 6.0, 7.0, 8.0, 9.0, 10.0, 11.0, 12.0, 13.0, 1

4.0, 15.0, 16.0, 17.0, 18.0, 19.0]

Sumas

[0.5]

3.5 Variables Aleatorias

Una variable aleatoria puede concebirse como un valor numérico que está afectado por el azar. Dada una variable aleatoria no es posible conocer con certeza el valor que tomará esta al ser medida o determinada, aunque sí se conoce que existe una distribución de probabilidad asociada al conjunto de valores posibles. (Wikipedia) Se emplea para nombrar a una función de valor real definida sobre un espacio muestral, es una función cuyo valor numérico depende del resultado de un experimento de azar.

Para definir las variables aleatorias Se utiliza letra mayúscula para la variable aleatoria y minúscula para la función de densidad:

$F(x)$ Función de distribución acumulada de x

$f(x)$ función de densidad de probabilidad (f.d.p) "función de densidad".

Existen metodos para obtener variables aleatorias:

- Método de la transformada inversa
- Metodo del rechazo para proposito de este libro vamos a revisar el **método de la transformada inversa**

Método de la transformada inversa

Consiste en generar un numero aleatorio comprendido entre 0 y 1, luego identificarlo con la función de distribución acumulativa $F(x)$, a través de la función inversa obtener el valor de x

1. Sea x el valor de la variable aleatoria y $f(x)$ la función de densidad de probabilidad
2. Obtener la función acumulativa $F(x)$

$$F(x) = \int_0^x f(t)dt$$

$F(x)$ nos indica el valor del área bajo la curva

Algoritmo

1. Conocer $f(x)$
2. calcular

$$F(x) = \int_0^x f(t)dt$$

3. Generar un número aleatorio con distribución uniforme $U(0,1)$
4. Identificarlo y aplicar la inversa $F(x) = r$ o $r = F(x)$
5. $X = F^{-1}r$ entre $0 \leq F(x) \leq 1$

$F(x)$ La función acumulativa indica la probabilidad que la variable aleatoria tome un valor de x

Ejemplo 1

Generar los valores aleatorios de x con una f.d.p $f(x) = 2x$ entre $0 \leq x \leq 1$

1. $f(x) = 2x$
2. $F(x) = \int_0^x f(t)dt$
3. $F(x) = \int_{-\infty}^0 f(t)dt + \int_0^x f(t)dt$
4. $F(x) = t^2 \mid \text{entre } 0 - x$
5. $F(x) = x^2$
6. Generamos un número aleatorio r
7. $F(x) = r$ por lo tanto $x^2 = r$
8. calculamos la inversa $x = \sqrt{r}$

In [31]:

```

1  # Ejecución del Algoritmo
2  # Generamos numeros aleatorios por cualquiera de los metodos presentados, pa
3  # de Borland C/C++ xi+1=22695477xi + 1 mod 2^32
4  # en una DataFrame dfMCL
5  # Anexamos la columna de la transformada inversa de $x = \sqrt{r}$, llanadole inv
6  # tomamos los datos del DataFrame
7
8
9
10
```

In [32]:

```

1  # probamos que este correcto
2
3  inv_xp = dfMCL[:1]
4  inv_xp
5
6  print(0.021137**1/2)
7  # resultado ok
8
```

0.0105685

```

In [33]: 1 # Graficamos Los numeros
          2
          3 t1 = dfMCL["ri"]
          4 t2 =inv_xp ## dfMCL["inv_xp"]
          5
          6 x=range(200)
          7 plt.figure(figsize=(50,15))
          8
          9 plt.subplot(131)
         10 p1, = plt.plot(x,t1,'r-')
         11 plt.xlabel('Secuencia x de números aleatorios')
         12 plt.ylabel('ALEATORIOS')
         13 plt.title('# ALEATORIOS POR METODO CONGRUENCIAL y TRANSFORMADA INVERSA')
         14 #print(t2)
         15 #plt.subplot(132)
         16 #p2, = plt.plot(x,t2,'b-')
         17 #plt.ylabel('ALEATORIOS')
         18 #plt.title('# ALEATORIOS POR TRANSFORMADA INVERSA')
         19 #plt.show()
         20 t2.plot(marker="o")
         21

```

```

C:\ProgramData\Anaconda3\lib\site-packages\pandas\plotting\_core.py:1001: Use
rWarning: Attempting to set identical left==right results
in singular transformations; automatically expanding.
left=0.0, right=0.0
  ax.set_xlim(left, right)

```

```

Out[33]: <matplotlib.axes._subplots.AxesSubplot at 0x1d14bf35518>

```

Ejemplo 2 con la función exponencial

El tiempo entre llegadas t a una instalación se representa con una distribución exponencial con media

$$E(t) = 1/\lambda$$

unidades de tiempo; es decir,

$$f(t) = \lambda e^{-\lambda t}, t > 0$$

Determinar una muestra aleatoria de t a partir de $f(t)$

La función Acumulada es la siguiente:

$$F(t) = \int_0^x \lambda e^{-\lambda t} dx = 1 - e^{-\lambda t}, t > 0; 0 \text{ at } t = 0$$

- $R = F(t)$ despejar t
- $t = -(1/\lambda) \ln(1 - R)$
- $(1 - R)$ es el complemento de R "reemplazar $\ln(1 - R)$ por $\ln(R)$ "
- $t = -(1/\lambda) \ln(R)$
- **Ejm. $\lambda = 4$ clientes x por hora $R = 0,9$**
- * $T1 = - (1/4) \ln (1 - 0,9) = 0,577$ *
- ** $t1 = -(1/4) \ln (0.9) = 0.0263$

tomado Ejemplo Taha, ejercicio 18.3-2

In [35]:

```
1 # comprobación del caso del libro de taha
2 import math
3 x = (1.0 - 0.9)
4 x1 = 0.9
5
6 lan=-1/4
7
8 print(math.log(x)*lan)
9 print(math.log(x1)*lan)
10
11
```

```
0.5756462732485115
0.02634012891445657
```

In [36]:

```
1 # Calculamos para los números aleatorios del ejemplo anterior
2 # Landa = 4 clientes por hora
3 landa=4
4 dfexp = dfMCL['ri']
5 # calculamos a todos los elementos la inversa
6 exp_x = dfexp.values*(-1/landa)*np.log(dfexp)
7 # anexamos al Datafram dfMCL
8 dfMCL["exp_x"] = exp_x
9 # Mostramos el resultado
10 dfMCL.head()
11
```


Out[36]:

	Xn	ri	exp_x
0	90781909	0.021137	0.020380
1	4261128730	0.992121	0.001962
2	705831779	0.164339	0.074192
3	274169216	0.063835	0.043910
4	2841246593	0.661529	0.068336

Type Markdown and LaTeX: α^2

```
In [37]: 1 dfgrafico = dfMCL.filter(items=['ri','inv_x','exp_x'])
          2
          3 dfgrafico.plot(figsize=(50,15))
          4
          5
```

Out[37]: <matplotlib.axes._subplots.AxesSubplot at 0x1d14bf7c8d0>



```
In [38]: 1 import math
          2 x = 0.1
          3 lan=-1/4
          4
          5 print(math.log(x)*lan)
          6
```

0.5756462732485114

3.6 Distribuciones de Frecuencia

Las dos distribuciones importantes para simulación más utilizadas son la Exponencial y la de Poisson

Distribución de Poisson

la distribución de Poisson es una distribución discreta usadas en simulación donde el área de oportunidad para la ocurrencia de un evento es grande, si se conoce el número promedio "éxitos" que ocurren. se utiliza en muchos sistemas de la vida real:

- Numeros de defectos de un determinado material
- Las imperfecciones de una placa de vidrio
- Número de accidentes automovilisticos producidos en una intersección de vehiculos
- Número de multas que detecta un radar por día
- La llegada de clientes a un sistemas de líneas de espera

Distribución de Poisson

Variable aleatoria discreta, la cual con frecuencia resulta útil cuando tratamos con el número de ocurrencias de un evento durante un intervalo específico de tiempo o espacio.

$$f(x) = e^{-\lambda} \lambda^x / x!$$

λ = media o número medio de ocurrencias en un intervalo, Cantidad promedio de "éxitos"


$e = 2.71828..$

x = número de ocurrencias en el intervalo 0, 1, 2, 3, 4, 5... valores posibles de x

$f(x)$ = probabilidad de x ocurrencias en el intervalo

Ejemplo

```
In [39]: 1 import numpy as np
2 import scipy.stats as stats
3 from scipy.stats import poisson
4 import matplotlib.pyplot as plt
5
6 landa = 5
7 poisson = stats.poisson(landa)
8 x = np.arange(poisson.ppf(0.01), poisson.ppf(0.99))
9
10 fmp = poisson.pmf(x)
11 plt.plot(x, fmp, '--')
12 plt.vlines(x, 0, fmp, colors='b', lw=5, alpha=0.5)
13 plt.title('Distribución de Poisson')
14 plt.ylabel('Probabilidad')
15 plt.xlabel('Valores')
16 plt.show()
17
```



In [40]:

1	fmp
2	

Out[40]: array([0.03368973, 0.08422434, 0.1403739 , 0.17546737, 0.17546737,
0.14622281, 0.10444486, 0.06527804, 0.03626558, 0.01813279])

In [41]:

1	x
---	---

Out[41]: array([1., 2., 3., 4., 5., 6., 7., 8., 9., 10.])